

MDI230 - PROJET VÉLIB

JUIN 2022

1. PRÉSENTATION

On considère un système de vélos partagés, type Vélib, où les vélos sont disponibles dans des stations dédiées et peuvent être empruntés pour faire des trajets d'une station à une autre. Le but de ce projet est de calculer les probabilités stationnaires que chaque station soit vide. Pour cela, il faut :

- Proposer une modélisation par un processus de Markov
- Ecrire un simulateur de ce processus de Markov pour 5 stations
- Calculer la probabilité stationnaire théorique dans le cas d'un unique vélo
- Comparer celle-ci au résultat de votre simulation pour un vélo pour valider votre simulation
- Simuler avec 100 vélos grâce à la simulation régénérative.

2. MODALITÉS

Le travail peut se faire en monôme, binôme, ou trinôme. Les groupes ne peuvent pas changer pendant la durée du projet ou d'un projet à l'autre. Vous pouvez faire la simulation dans le langage de votre choix, nous vous conseillons Python ou Matlab.

- Pour le cours du 7 juin : vous devez lire document sur le modèle des colonies disponible sur le Moodle.
- Le 7 juin, nous vous présenterons en séance le projet
- Vous aurez à travailler en groupe et à rendre sur papier vos résultats de modélisation puis de calibration pendant la séance du 7 juin (travail correspondant à la section 3 de ce document). **Votre présence est donc obligatoire le 7 juin pour avoir une note sur cette partie là.**
- Le corrigé sera donné en séance pour pouvoir poursuivre le travail et sera mis en ligne sur Moodle le 7 juin à 19h. Seront fournis la modélisation que nous souhaitons que vous étudiez, les paramètres et formules nécessaires à la calibration du modèle, et les données de simulation.
- Vous devez déposer sur le Moodle votre rapport final au format pdf contenant les réponses aux questions théoriques ci-après, et les résultats obtenus par simulation pour le **21 juin 2021 à 23h59**. Le code peut être donné en annexe ou en Python Notebook.

3. MODÉLISATION

On suppose que la capacité des stations est illimitée pour l'accueil des vélos, c'est-à-dire que l'on peut toujours rendre un vélo dans une station. On suppose aussi que tous les trajets se font d'une station à une autre exclusivement, il n'est pas possible de revenir à la même station.

1. Lisez le document sur le modèle des colonies disponible sur le site pédagogique (extrait du livre *Lectures on stochastic networks* par F. Kelly et E. Yudovin).
2. Inspirez-vous de ce modèle pour proposer une modélisation du Vélib.
 - Donnez l'espace d'états, et les colonies de votre modèle.
 - Tracez le diagramme des transitions possibles entre les colonies (limiter le dessin à quelques stations)
 - Indiquez les taux de transitions.
 - Donnez les paramètres de votre modèle, précisez les unités.

4. SIMULATION

On propose d'étudier le Vélib de Rouen dans sa configuration de 2016 qui possédait 21 stations. Pour la simulation, on ne conserve que 5 stations (stations 3 à 7), les paramètres calculés sont donnés dans le fichier Excel *Donnees_simulations.xlsx* mis à disposition sur le Moodle, ou ci-dessous. Vous pouvez utiliser les conditions initiales que vous le souhaitez, des conditions initiales possibles sont données dans le fichier Excel. Des aides pour la simulation sont données à la fin de ce document.

Station	3	4	5	6	7
3		3	5	7	7
4	2		2	5	5
5	4	2		3	3
6	8	6	4		2
7	7	7	5	2	
Temps moyen de trajet τ_{ij} en minutes					
Station	3	4	5	6	7
	2,8	3,7	5,5	3,5	4,6
Taux de départ par heure λ_i					
Station	3	4	5	6	7
3		0,22	0,32	0,2	0,26
4	0,17		0,34	0,21	0,28
5	0,19	0,26		0,24	0,31
6	0,17	0,22	0,33		0,28
7	0,18	0,24	0,35	0,23	
Matrice de routage p_{ij}					

3. Simulez les trajectoires du processus de Markov.
4. En déduire la probabilité que chaque station soit vide après 150 heures.
5. Calculer l'intervalle de confiance de ce résultat.

5. CALCUL THÉORIQUE

Une fois écrit votre simulateur, qui sortira forcément des résultats, il faut valider votre code par des résultats théoriques.

6. Utilisez les équations de trafic pour obtenir les relations entre les α_i (notations du document sur les colonies).
7. On considère qu'il n'y a qu'un seul vélo, quelle est alors la taille de l'espace d'état ?
8. Dans ces conditions (un seul vélo), calculer la probabilité que chaque station soit vide.
9. Comparez aux résultats obtenus par simulation.

Pour résoudre numériquement le système d'équations donnant les α_i , on suggère de mettre le système sous forme de calcul matriciel $M\alpha = X$ où α est le vecteur colonne des α_i . On a alors $\alpha = M^{-1}X$. Pour éviter $X = 0$, on pourra remplacer une ligne de M par des 1, on a en effet $n+1$ équations pour n inconnues si on ajoute la condition de normalisation.

6. SIMULATION POUR 100 VÉLOS

10. Simuler le même réseau avec 100 vélos, initialement répartis de façon uniforme entre les stations et les routes.
11. Calculer la probabilité stationnaire que chaque station soit vide par la méthode décrite en section 7.4. On n'oubliera pas de préciser l'intervalle de confiance.

Date limite : 21 juin 2021 à 23h59

7. AIDES POUR LA SIMULATION

7.1. Accélération de votre simulation en Python. Si vous voulez accélérer notablement votre simulation, vous pouvez utiliser la commande `@jit` de la librairie *numba* avant la définition de chaque fonction.

```
1 from numba import jit
2
3 @jit
4 def pickState(p):
5     r=np.cumsum(p)
6     r =r/np.sum(p)
7     u=np.random.rand()
8     w=0
9     while(u>r[w]):
10
11         w+=1
12     return w
```

LISTING 1. Simulation d'une variable aléatoire discrète à valeurs dans $0, 1, \dots, N$ où N est la longueur du vecteur de probabilité passé en paramètre

7.2. Simulation d'une variable aléatoire discrète. Le code ci-dessus met en œuvre l'algorithme de simulation qui suit. Soit X une variable aléatoire discrète et $E = \{x_1, x_2, x_3\}$ son espace d'états. On note $p_i = \mathbf{P}[X = x_i]$ pour $i = 1, 2, 3$ avec $\sum_{i=1}^3 p_i = 1$. On tire une variable aléatoire u uniforme sur $[0, 1]$, alors :

- Si $u \leq p_1$, $\hat{X} = x_1$ et $\mathbf{P}[\hat{X} = x_1] = p_1$,
- Si $p_1 < u \leq p_1 + p_2$, $\hat{X} = x_2$ et $\mathbf{P}[\hat{X} = x_2] = p_1 + p_2 - p_1 = p_2$,
- Si $p_1 + p_2 < u$, $\hat{X} = x_3$ et $\mathbf{P}[\hat{X} = x_3] = 1 - (p_1 + p_2) = p_3$.

Ainsi, \hat{X} a la même loi que X .

7.3. Intervalles de confiance. On rappelle que l'intervalle de confiance d'une quantité $\theta = \mathbf{E}[X]$ estimée sur n tirages X_1, \dots, X_n de moyenne $\hat{\theta}_n = \frac{1}{n} \sum_{i=1}^n X_i$ est l'intervalle de la forme $[\hat{\theta}_n - \varepsilon, \hat{\theta}_n + \varepsilon]$ dans lequel on est sûr à $\alpha\%$ que se trouve θ . On a $\varepsilon = \beta \sigma_n / \sqrt{n}$ avec :

- σ_n l'écart-type empirique sur les tirages :

$$\sigma_n^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \hat{\theta}_n)^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j)^2 - \frac{n}{n-1} \hat{\theta}_n^2.$$

Si les X_j valent 0 ou 1, alors $X_j^2 = X_j$ et,

$$\sigma_n^2 = \frac{n}{n-1} (\hat{\theta}_n - \hat{\theta}_n^2).$$

- $\beta = 1,96$ pour $\alpha = 0,95$.

7.4. Simulation régénérative. On sait que la probabilité stationnaire d'une chaîne de Markov irréductible, récurrente peut s'écrire

$$\pi(y) = \frac{1}{\mathbf{E}\tau_x^1} \mathbf{E}_x \left[\sum_{j=0}^{\tau_x^1-1} \mathbf{1}_{\{X_j=y\}} \right]$$

où τ_x^1 est l'instant de premier retour en x partant de x . De manière plus générale

$$\bar{z} = \sum_{y \in E} f(y) \pi(y) = \frac{1}{\mathbf{E}\tau_x^1} \mathbf{E}_x \left[\sum_{j=0}^{\tau_x^1-1} f(X_j) \right].$$

Simulons R cycles de x à lui-même, soit (d_1, \dots, d_R) leur longueur, i.e. $d_j = \tau_x^j - \tau_x^{j-1}$. Soit

$$Y_l = \sum_{j=\tau_x^{l-1}}^{\tau_x^l} f(X_j).$$

Les $((d_k, Y_k), k \in \{1, \dots, R\})$ sont indépendants et identiquement distribués donc

$$\begin{aligned} \hat{\tau}_R &= \frac{1}{R} \sum_{k=1}^R d_k \xrightarrow{\text{p.s.}} \mathbf{E}_x[\tau_x] = \bar{\tau} \\ \hat{Y}_R &= \frac{1}{R} \sum_{k=1}^R Y_k \xrightarrow{\text{p.s.}} \mathbf{E}_x \left[\sum_{j=0}^{\tau_x-1} f(X_j) \right] = \bar{y} \\ \sqrt{R} \left((\hat{\tau}_R, \hat{Y}_R) - (\bar{\tau}, \bar{y}) \right) &\xrightarrow{\text{loi}} \mathcal{N}(0, \Gamma) \end{aligned}$$

avec

$$\Gamma = \begin{pmatrix} \text{var}(\tau_x^1) & \text{cov}(\tau_x^1, Y_1) \\ \text{cov}(\tau_x^1, Y_1) & \text{var}(Y_1^2) \end{pmatrix}.$$

Un estimateur consistant mais biaisé de \bar{z} est donné par

$$\hat{z}_R = \frac{\hat{Y}_R}{\hat{\tau}_R}.$$

La précision de cet estimateur est donné par

$$\sqrt{R}(\hat{z}_R - \bar{z}) \xrightarrow{\text{Loi}} \mathcal{N}(0, \eta^2)$$

où

$$\eta^2 = \gamma_{11} \frac{\bar{y}^2}{\bar{\tau}^4} - 2\gamma_{12} \frac{\bar{y}}{\bar{\tau}^3} + \gamma_{22} \frac{1}{\bar{\tau}^2}.$$

L'intervalle de confiance à 95% est donc donné par

$$\bar{z} \in]\hat{z}_R - \frac{1,95 \eta_R}{\sqrt{R}}, \hat{z}_R + \frac{1,95 \eta_R}{\sqrt{R}}[.$$

Comme on ne connaît pas a priori ni les γ_{ij} , ni \bar{y} , ni $\bar{\tau}$ on les remplace par leur version « empirique » : $\bar{\tau}$ est remplacé par $\hat{\tau}_R$, \bar{y} est remplacé par \hat{Y}_R et γ_{ij} par

$$\hat{\gamma}_{12}^R = \frac{1}{R-1} \sum_{k=1}^R d_k Y_k - \hat{\tau}_R \hat{Y}_R$$

$$\hat{\gamma}_{11} = \frac{1}{R-1} \sum_{k=1}^R d_k^2 - \hat{\tau}_R^2$$

$$\hat{\gamma}_{22} = \frac{1}{R-1} \sum_{k=1}^R Y_k^2 - \hat{Y}_R^2$$